Métodos matemáticos e estatísticos

Análise de curvas de luz de estrelas variáveis

Sumário

1. Notação e hipóteses **2**

2. Leitura, validade e corte robusto **2**

3. Grade de frequências e Lomb–Scargle **3**

4. Picos e sementes de modelos **4**

5. Janela espectral e classificação de aliases **4**

6. Ajuste de Fourier e diagnósticos numéricos **5**

7. Refinamento local e seleção por BIC **6**

8. FAP de Baluev **7**

9. Bootstrap condicional com janela temporal fixa **8**

Reamostragem de resíduos 8

Reamostragem paramétrica 8

Recuperação do pico e intervalos 8

10. Fases e médias ponderadas por bin **9**

11. Amplitudes e parâmetros de forma **10**

12. Interpretação e reprodutibilidade **11**

Referências bibliográficas **12**

Este documento descreve a implementação existente nos módulos Python, incluindo suas convenções e escolhas numéricas. As equações traduzem o código; as referências dão o fundamento dos métodos. Os limiares e regras locais de seleção são identificados como escolhas do projeto, sem atribuí-los automaticamente aos artigos citados.

1. Notação e hipóteses

Para cada observação i, usam-se tempo t_i em dias, magnitude m_i e incerteza σ_i em magnitude. Há N observações após os filtros. Definem-se:

$$t_0 = \min_i t_i, \qquad x_i = t_i - t_0, \qquad T = \max_i t_i - \min_i t_i, \qquad w_i = \sigma_i^{-2}.$$

As frequências f estão em ciclos por dia, o período é $P = 1/f$ e as fases estão em ciclos. H é o número de harmônicos; $p = 1 + 2H$ é a quantidade de coeficientes lineares do modelo de Fourier.

O modelo de observação que fundamenta mínimos quadrados e sua interpretação estatística é:

$$m_i = \mu(x_i; f, \beta) + \epsilon_i, \qquad E[\epsilon_i] = 0, \qquad \mathrm{Var}(\epsilon_i) = \sigma_i^2.$$

O programa usa uma matriz de pesos diagonal: não modela correlação entre erros. A interpretação de χ^2 e do BIC como derivados de uma verossimilhança exige adicionalmente erros gaussianos independentes e incertezas adequadamente calibradas. O ajuste numérico em si minimiza a soma ponderada mesmo quando essas hipóteses não são satisfeitas.

Tempos e incertezas são tratados como conhecidos; não se propagam erros nos tempos. O sinal ajustado tem uma frequência fundamental fixa e seus harmônicos, sem variação temporal de frequência ou amplitude. Não há ajuste conjunto de frequências independentes, tendências ou offsets por observador/banda.

2. Leitura, validade e corte robusto

Implementação: dados.carregar_dados.

O pandas infere o separador, ignora comentários iniciados em `#`, remove espaços externos dos nomes de colunas e converte `JD`, `Magnitude` e `Uncertainty` em números. Após os filtros de banda e observador, ficam somente linhas com os três valores finitos e $\sigma_i > 0$. Tempos repetidos são preservados e tratados como observações independentes.

Se `sigma_clip=s` for informado, calculam-se, uma única vez:

$$\widetilde{m} = \mathrm{mediana}(m_i), \qquad S_{\mathrm{MAD}} = 1.4826\,\mathrm{mediana}(|m_i - \widetilde{m}|).$$

Para $S_{\mathrm{MAD}} > 0$, mantém-se a observação quando:

$$|m_i - \widetilde{m}| \le s S_{\mathrm{MAD}}.$$

O fator 1,4826 aproxima a calibração da MAD para o desvio padrão de uma normal. Essa definição de escala robusta é discutida por Rousseeuw & Croux (1993). O corte é aplicado às magnitudes, sem pesos e sem usar resíduos de um modelo; não é iterativo. Quando a MAD é zero, nenhum ponto é removido por esse corte. Por padrão, não há clipping: extremos de magnitude podem ser parte física da curva periódica, especialmente em sinais assimétricos.

A rotina de análise exige vetores unidimensionais, finitos, de igual tamanho, $N > p_{\max} + 1$ e $T > 0$. A contagem usa a ordem máxima solicitada, mesmo quando se permite selecionar ordens menores. O programa não verifica automaticamente independência, normalidade ou compatibilidade entre sistemas fotométricos.

3. Grade de frequências e Lomb–Scargle

Implementação: lomb_scargle.py e preparação em analise.analisar_serie.

Os limites solicitados em período são convertidos em:

$$P_{\max,\mathrm{ef}} = \min(P_{\max}, T), \qquad f_{\min} = 1/P_{\max,\mathrm{ef}}, \qquad f_{\max} = 1/P_{\min}.$$

Exige-se $P_{\min} < P_{\max,\mathrm{ef}}$. Se o período máximo for reduzido ao intervalo observado, a rotina emite um aviso. A escala usada para largura de picos e comparações é:

$$\Delta f_{\mathrm{res}} = 1/T.$$

Ela é uma escala de resolução, não um erro estimado da frequência. Com q=`amostras_por_pico`, o Astropy 7.0.1 usado na validação gera:

$$\delta f = \frac{1}{Tq}, \qquad N_f = 1 + \mathrm{round}\left(\frac{f_{\max} - f_{\min}}{\delta f}\right), \qquad f_j = f_{\min} + j\delta f, \quad j = 0, \ldots, N_f - 1.$$

O último ponto pode diferir ligeiramente do limite solicitado por causa do arredondamento. Os limites explícitos evitam depender do limite automático baseado na frequência média de Nyquist. A grade e a potência são calculadas por `autofrequency(...)` e `power(...,method="auto")`; a seleção do algoritmo interno fica a cargo do Astropy. Consulte a API LombScargle.

A cada frequência, o modelo sinusoidal com média flutuante é:

$$\mu_i(f) = c + a\sin(2\pi f x_i) + b\cos(2\pi f x_i).$$

O objeto é configurado com `dy=erro`, `fit_mean=True`, `center_data=True`, `nterms=1` e `normalization="standard"`. A centralização inicial ponderada não elimina o ajuste da constante c em cada frequência. O periodograma ponderado com offset ajustável é apresentado por Zechmeister & Kürster (2009), a partir da formulação de mínimos quadrados associada a Lomb (1976) e Scargle (1982).

Com

$$\overline{m}_w = \frac{\sum_i w_i m_i}{\sum_i w_i}, \qquad \chi^2_{\mathrm{ref}} = \sum_i w_i (m_i - \overline{m}_w)^2,$$

$$\chi^2_1(f) = \min_{c,a,b} \sum_i w_i [m_i - \mu_i(f)]^2,$$

a normalização usada é:

$$z(f) = \frac{\chi^2_{\text{ref}} - \chi^2_1(f)}{\chi^2_{\text{ref}}}.$$

Essa potência é adimensional. Em aritmética exata e com variância de referência positiva, pertence a [0,1]; o programa não a recorta numericamente nesse intervalo. Potências não finitas levam a `RuntimeError`. A formulação está na documentação de normalizações do Astropy. O periodograma inicial sempre tem um harmônico, mesmo quando o ajuste final permite vários.

4. Picos e sementes de modelos

Implementação: `indices_picos_distintos` em lomb_scargle.py e `selecionar_candidatos` em selecao_modelos.py.

A distância mínima em índices enviada a `scipy.signal.find_peaks` é:

$$d = \max\left(1, \left\lceil \frac{\Delta f_{\text{res}}}{\text{mediana}(\text{diff}(f_j))} \right\rceil\right).$$

Depois, são acrescentados o máximo global e os extremos da grade quando cada extremo tem potência maior ou igual à de seu vizinho. A restrição de distância não é reaplicada a esses pontos acrescentados. A lista é ordenada por potência decrescente e truncada em `n_candidatos`.

A partir dos até cinco maiores picos, também se consideram $f/2$ e $f/3$ dentro dos extremos efetivos da grade. As sementes são ordenadas pela potência LS avaliada na própria frequência, antes do refinamento. Assim, `n_candidatos` limita os picos iniciais e não necessariamente o número final de modelos.

Essa busca por sub-harmônicos é uma escolha do projeto para investigar casos em que um harmônico domina o periodograma sinusoidal. Não é uma busca exaustiva por todas as periodicidades possíveis. A relação entre forma do sinal, amostragem e picos é discutida por VanderPlas (2018).

5. Janela espectral e classificação de aliases

Implementação: janela_espectral.py.

A janela do projeto é obtida aplicando Lomb–Scargle aos mesmos tempos e a um vetor de valores unitários. Usa `fit_mean=False`, `center_data=False`, `normalization="standard"`, sem incertezas e sem pesos fotométricos. Traduzindo essa configuração para mínimos quadrados:

$$\chi^2_W(f) = \min_{a,b} \sum_i [1 - a\sin(2\pi f x_i) - b\cos(2\pi f x_i)]^2, \qquad W_{\text{LS}}(f) = \frac{N - \chi^2_W(f)}{N}.$$

Essa equação descreve a configuração implementada. Ela não deve ser substituída pela definição usual de janela de Fourier

$$W_{\mathrm{DFT}}(f) = \frac{1}{N^2}\left|\sum_i e^{-2\pi \mathrm{i} f x_i}\right|^2,$$

pois as normalizações e a projeção sobre as bases seno/cosseno são diferentes. A discussão geral de janelas e aliases pode ser consultada em VanderPlas (2018); a escolha de W_{LS} acima é a que consta no código deste projeto.

A grade da janela começa em Δf_{res} e usa o passo mediano da grade LS, com `np.arange(Δf_res,f_max+0.5*passo,passo)`. São selecionados até oito picos.

Para uma frequência candidata f e a selecionada f*, a classificação segue a primeira condição satisfeita, nesta ordem:

1. `selecionado` se $|f - f_*| \le \Delta f_{\mathrm{res}}$;
2. `harmônicokf` se $|f - kf_*| \le \Delta f_{\mathrm{res}}$, para $k = 2, 3$;
3. `sub-harmônicof/k` se $|kf - f_*| \le \Delta f_{\mathrm{res}}$, testado junto com cada k acima;
4. `possívelalias` se f estiver a até Δf_{res} de $|kf_* \pm r f_W|$, para cada pico da janela, $k = 1, 2, 3$, $r = 1, 2$, sinal positivo antes do negativo;
5. `alternativo` se nenhuma condição for atendida.

Não são fixados aliases diários ou anuais a priori: usam-se os picos medidos da janela. Um rótulo de possível alias expressa proximidade em frequência; não constitui uma probabilidade nem um veto à seleção do candidato.

6. Ajuste de Fourier e diagnósticos numéricos

Implementação: fourier.py.

A fase usada na matriz é $\phi_i = \mathrm{remainder}(f x_i, 1)$. O modelo é:

$$\mu_i = c + \sum_{k=1}^{H} \left[a_k \sin(2\pi k \phi_i) + b_k \cos(2\pi k \phi_i)\right].$$

A matriz X tem N linhas e $p = 1 + 2H$ colunas, na ordem `[1,sin(2πφ),cos(2πφ),…]`. Com $\beta =$`[c,a1,b1,…,aH,bH]`, o código resolve:

$$\hat{\beta} = \arg\min_{\beta} \|X_w \beta - m_w\|_2^2, \qquad (X_w)_{ij} = X_{ij}/\sigma_i, \qquad (m_w)_i = m_i/\sigma_i.$$

A solução é calculada com `numpy.linalg.lstsq(...,rcond=None)`, que fornece coeficientes, posto e valores singulares. O código não forma explicitamente a inversa das equações normais. Consulte a API de numpy.linalg.lstsq.

Definem-se resíduos $r_i = m_i - \hat{\mu}_i$ e:

$$\chi^2 = \sum_i (r_i/\sigma_i)^2, \qquad \mathrm{RMS}_w = \sqrt{\frac{\sum_i w_i r_i^2}{\sum_i w_i}}, \qquad \chi^2_{\mathrm{red}} = \frac{\chi^2}{N - p}.$$

O RMS tem unidade de magnitude e χ^2 é adimensional. Quando $N - p \leq 0$, `chi2_reduzido` é NaN. Essa contagem de graus de liberdade é a implementada: não desconta o parâmetro de frequência refinado posteriormente. Portanto, a interpretação usual de χ^2 reduzido é condicionada à frequência, e pode ser alterada pela seleção do modelo nos próprios dados.

O número de condição registrado é $\kappa = s_{\max}/s_{\min}$ da matriz ponderada. Posto menor que p, menor valor singular não positivo, coeficientes não finitos ou BIC não finito tornam o ajuste inválido. Um número de condição elevado, por si só, não aciona nenhum limiar adicional de rejeição. Não há regularização, normalização dos erros pelo χ^2 reduzido ou ajuste das médias de bins.

7. Refinamento local e seleção por BIC

Implementação: selecao_modelos.py.

Para uma semente f_s, o intervalo de refinamento é:

$$I_s = [\max(f_{\text{grade,min}}, f_s - \Delta f_{\text{res}}/2), \min(f_{\text{grade,max}}, f_s + \Delta f_{\text{res}}/2)].$$

Para cada ordem $H = 1, \ldots, H_{\max}$, ou apenas $H_{\max}$ com `ordem_fixa=True`, são avaliados 25 pontos uniformes nesse intervalo. O menor χ^2 finito define um subintervalo entre seus vizinhos. Havendo largura positiva, chama-se `minimize_scalar(method="bounded")`, minimizando χ^2, com:

$$\text{xatol} = \max(\Delta f_{\text{res}}/10000, 10^{-12}).$$

A frequência do otimizador é usada quando ele sinaliza sucesso e objetivo finito; caso contrário, permanece o ponto escolhido na grade local. Intervalo não positivo usa a frequência inicial. Ajustes com erros numéricos tratados são descartados. Essa é uma busca local; não garante o mínimo global entre todas as frequências. O método limitado é descrito na documentação do SciPy.

O BIC geral penaliza a dimensão do modelo e decorre de uma aproximação assintótica da evidência bayesiana. Veja Schwarz (1978). Para erros gaussianos conhecidos e os mesmos dados, o programa usa:

$$\text{BIC} = \chi^2 + p \ln N, \qquad p = 1 + 2H.$$

O termo de normalização da verossimilhança, constante entre esses ajustes, não é somado. **A frequência refinada não é contada em p.** O documento registra essa convenção do código, sem reinterpretá-la como uma contagem completa de todos os parâmetros estimados.

Escolhe-se o menor BIC entre as ordens de cada semente. Soluções refinadas separadas por menos de $0{,}5\Delta f_{\text{res}}$ são tratadas como duplicadas; a primeira correspondência é substituída se a nova tiver BIC menor. Entre os ajustes restantes, define-se:

$$\Delta\text{BIC}_j = \text{BIC}_j - \min_{\ell} \text{BIC}_\ell, \qquad \mathcal{C} = \{j : \Delta\text{BIC}_j \leq 2\}.$$

Dentro de C, vence a maior potência LS na frequência refinada; em empate dessa potência, vence a menor ordem H. Empates completos seguem a ordem da lista. O

selecionado vai para a primeira posição e os demais seguem BIC crescente. Por isso, o selecionado pode não ser o mínimo absoluto de BIC.

O limiar 2 e o desempate por potência são regras locais do projeto, não uma probabilidade posterior. O teste executável é $\Delta\mathrm{BIC} \leq 2$; a mensagem histórica do terminal e um comentário dizem "<2". A documentação explicita a diferença, sem alterar a mensagem ou o critério implementado.

8. FAP de Baluev

Implementação: `calcular_significancia` em estatistica.py.

Primeiro se escolhe $z_{\max} = \max_j z(f_j)$ da grade sinusoidal. A probabilidade de falso alarme diz respeito ao evento de observar um máximo pelo menos tão alto sob a hipótese nula de média constante com ruído gaussiano independente:

$$\mathrm{FAP}(z_{\max}) = \Pr\{\max_f z(f) \geq z_{\max} \mid H_0\}.$$

São chamadas as APIs `false_alarm_probability(...,method="baluev")` e `false_alarm_level([0.10,0.05,0.01],method="baluev")`, usando os limites e a sobreamostragem da busca. O procedimento se baseia em valores extremos, conforme Baluev (2008). É uma aproximação analítica associada ao caso sem aliases fortes; a forma numérica é delegada ao Astropy.

Para registrar a forma usada no ambiente validado, a implementação do Astropy 7.0.1 usa, com normalização `standard`, $N_H = N - 1$ e $N_K = N - 3$:

$$q_1(z) = (1 - z)^{N_K/2}, \qquad T_{\mathrm{ef}} = \sqrt{4\pi\,\mathrm{Var}_w(x)}, \qquad W = f_{\max,\mathrm{ef}} T_{\mathrm{ef}},$$

$$g(n) = \sqrt{\frac{2}{n}}\frac{\Gamma(n/2)}{\Gamma((n-1)/2)}, \qquad \tau(z) = g(N_H) W (1 - z)^{(N_K-1)/2}\sqrt{N_H z/2},$$

$$\mathrm{FAP}_{\mathrm{Baluev}}(z) \approx 1 - [1 - q_1(z)]e^{-\tau(z)}.$$

Aqui $\mathrm{Var}_w(x) = \frac{\sum_i w_i x_i^2}{\sum_i w_i} - \left(\frac{\sum_i w_i x_i}{\sum_i w_i}\right)^2$, Γ é a função gama, e $f_{\max,\mathrm{ef}}$ é o limite superior efetivo obtido pela biblioteca a partir da grade. Em particular, esse fator W da biblioteca não é simplesmente $(f_{\max} - f_{\min})T$. A avaliação numérica usa `expm1` para melhorar a precisão; as equações acima são uma representação matemática, não uma implementação alternativa.

Essa FAP pertence ao maior pico **sinusoidal na grade**, não ao modelo Fourier refinado escolhido por BIC. Ela também não mede a chance de que o pico escolhido seja o período físico correto, nem a probabilidade de a estrela ser aperiódica. Essas distinções são discutidas na documentação de significância do Astropy.

Ruído correlacionado, erros inadequados ou tendências não modeladas comprometem a interpretação. O programa não realiza testes dessas hipóteses. Se uma das chamadas de significância lançar `ValueError`, `FloatingPointError` ou `OverflowError`, toda essa etapa retorna FAP=NaN e níveis vazios, mantendo as informações do pico.

9. Bootstrap condicional com janela temporal fixa

Implementação: `bootstrap_periodos` e `resumir_bootstrap` em estatistica.py.

O princípio de reamostrar para aproximar uma distribuição amostral é descrito por Efron (1979). A aplicação específica aqui é condicional ao modelo selecionado, aos tempos, às incertezas e à grade. Não é o bootstrap de FAP sob ausência de sinal: cada réplica é construída em torno de um sinal periódico ajustado.

Reamostragem de resíduos

Com o modelo base $\hat{\mu}_i$ e resíduos r_i, o código calcula:

$$u_i = \frac{r_i}{\sigma_i}, \qquad \overline{u} = \frac{1}{N}\sum_i u_i, \qquad v_i = (u_i - \overline{u})\sqrt{\frac{N}{N-p}},$$

usando o fator de correção somente quando $N - p > 0$. A média de u é aritmética, sem pesos adicionais. Para cada réplica b, sorteiam-se N valores v_i^* com reposição da coleção $\{v_i\}$, e gera-se:

$$m_i^{*(b)} = \hat{\mu}_i + \sigma_i v_i^{*(b)}.$$

A interpretação presume que os resíduos padronizados são aproximadamente intercambiáveis e que representam o ruído em torno do modelo. A reamostragem não preserva autocorrelação e não faz correção individual por alavancagem.

Reamostragem paramétrica

O outro método usa sorteios independentes $\eta_i \sim \mathcal{N}(0,1)$:

$$m_i^{*(b)} = \hat{\mu}_i + \sigma_i \eta_i^{(b)}.$$

Não se multiplica esse ruído por χ^2 reduzido ou pelo RMS residual. A hipótese é que as incertezas fornecidas descrevem a escala de ruído gaussiano.

Nos dois casos, tempos, erros e grade permanecem fixos. O gerador é `numpy.random.default_rng(semente)`. Cada réplica recalcula o LS e repete a seleção com até `min(n_candidatos,8)` picos iniciais, sub-harmônicos ativados e a mesma regra de ordem fixa ou seleção por BIC. Réplicas sem ajuste válido, ou com os erros numéricos tratados, não contribuem para o vetor final.

Recuperação do pico e intervalos

Com B réplicas solicitadas e B_v válidas, define-se recuperação do mesmo pico por:

$$I_b = 1\{|1/P_b^* - 1/P_*| \le \Delta f_{\text{res}}\}, \qquad r_{\text{valido}} = B_v/B, \qquad r_{\text{pico}} = \frac{1}{B_v}\sum_{b=1}^{B_v} I_b.$$

Com pelo menos cinco recuperações, calculam-se P16, mediana e P84 apenas dos períodos com $I_b = 1$. Esse é um intervalo percentílico **condicional ao mesmo pico**,

sem correção de viés ou garantia de cobertura. Não resume os modos alternativos. Sem réplicas válidas, as frações indefinidas são NaN e o intervalo é `None`; com $B = 0$, a fração válida também é NaN.

Para descrever modos, as frequências válidas são ordenadas. Uma frequência abre novo grupo se sua distância para a mediana do último grupo for maior que Δf_{res}; caso contrário, entra nesse grupo. Os cinco grupos mais numerosos são reportados com fração relativa a B_v e período:

$$P_{\text{grupo}} = 1/\,\text{mediana}(f_b^* \text{ do grupo}).$$

Esse valor é o inverso da mediana em frequência, não necessariamente a mediana dos períodos. O terminal emite avisos para fração válida abaixo de 0,95 ou recuperação do pico abaixo de 0,8, quando há réplicas válidas. Esses limiares são diagnósticos definidos pelo projeto.

10. Fases e médias ponderadas por bin

Implementação: `analisar_serie` e `binning_ponderado`.

Após a escolha do modelo, as fases $\phi_i = \text{remainder}(f_* x_i, 1)$ são ordenadas. O intervalo [0,1] é dividido em `n_bins` partes uniformes. Bins com menos de duas observações são omitidos. Para um bin B:

$$\overline{\phi}_B = \frac{\sum_{i\in B} w_i \phi_i}{\sum_{i\in B} w_i}, \qquad \overline{m}_B = \frac{\sum_{i\in B} w_i m_i}{\sum_{i\in B} w_i},$$

$$s_{\text{formal,B}} = \sqrt{1/\sum_{i\in B} w_i}, \qquad N_{\text{ef,B}} = \frac{(\sum_{i\in B} w_i)^2}{\sum_{i\in B} w_i^2},$$

$$s_B = \sqrt{\frac{\sum_{i\in B} w_i (m_i - \overline{m}_B)^2}{\sum_{i\in B} w_i}}, \qquad s_{\text{exibido,B}} = \max\left(s_{\text{formal,B}}, \frac{s_B}{\sqrt{\max(N_{\text{ef,B}}, 1)}} \right).$$

O primeiro termo é o erro formal da média sob independência e variâncias conhecidas; o segundo incorpora descritivamente a dispersão dentro do bin. O máximo entre eles é a regra implementada para as barras do gráfico, não um intervalo de confiança derivado para qualquer distribuição. O desvio s_B não recebe correção de graus de liberdade. As médias de fase são aritméticas ponderadas dentro de cada bin, sem unir bins próximos de 0 e 1.

O binning não participa do LS, do ajuste de Fourier, do BIC ou do bootstrap. Essas etapas usam as observações individuais.

11. Amplitudes e parâmetros de forma

Implementação: `parametros_fourier` e a etapa final de `analisar_serie`.

Para os coeficientes do modelo em seno e cosseno, a convenção adotada é:

$$a_k \sin\theta + b_k \cos\theta = A_k \cos(\theta + \psi_k), \qquad A_k = \sqrt{a_k^2 + b_k^2}, \qquad \psi_k = \operatorname{atan2}(-a_k, b_k).$$

As combinações reportadas são:

$$R_{21} = A_2 / A_1, \qquad \phi_{21} = (\psi_2 - 2\psi_1) \bmod 2\pi.$$

A_1 e A_2 estão em magnitude, R_{21} é adimensional e ϕ_{21} está em radianos. Com menos de um harmônico, todos esses valores são NaN; com apenas um, somente A_1 é definido. Quando existem dois harmônicos, usa-se a tolerância:

$$\varepsilon_A = 100\, \varepsilon_{\text{float}} \max(1, \max_j |\beta_j|).$$

Se $A_1 \le \varepsilon_A$ ou $A_2 \le \varepsilon_A$, ϕ_{21} é NaN. R_{21} é NaN quando $A_1 \le \varepsilon_A$; caso contrário, a razão é preservada mesmo quando A_2 é numericamente pequena. A_1 e A_2 continuam sendo os valores calculados, sem substituição por zero.

O modelo é amostrado em 1.000 fases de 0 a 1, incluindo os extremos. A amplitude reportada é uma aproximação obtida nessa grade:

$$A_{\text{pp}} = \max_j \hat{\mu}(\phi_j) - \min_j \hat{\mu}(\phi_j), \qquad A_{\text{semi}} = A_{\text{pp}}/2.$$

Também se calcula o intervalo não ponderado das magnitudes observadas:

$$A_{90} = Q_{0.95}(m) - Q_{0.05}(m).$$

Os percentis usam `numpy.percentile` com as opções padrão da dependência. Nenhuma dessas amplitudes é convertida para fluxo. O eixo de magnitude é invertido nos gráficos; isso não altera os valores ajustados.

12. Interpretação e reprodutibilidade

Quantidade	O que o programa avalia	Limite de interpretação
Maior pico LS	Melhor potência sinusoidal amostrada na grade	Pode corresponder a harmônico ou alias.
Modelo selecionado	Fourier refinado conforme BIC e desempate	Depende das sementes, limites e ordens examinadas.
FAP	Máximo LS sob ruído gaussiano sem periodicidade	Não identifica qual pico é fisicamente correto.
Fração do mesmo pico	Estabilidade condicional nas réplicas válidas	Depende do modelo e do ruído assumidos.
P16/P50/P84	Dispersão entre réplicas que recuperam o pico	Não abrange os modos alternativos.
χ^2 reduzido	Resíduos relativos aos erros, com $N - p$ no denominador	Usa a contagem de parâmetros indicada no código.
Janela e rótulos	Compatibilidade em frequência com a amostragem	Diagnóstico sem teste probabilístico próprio.

A reprodutibilidade numérica requer os mesmos dados, parâmetros, semente e ambiente numérico. O arquivo requirements-testes.txt registra as versões utilizadas. Os cálculos internos do Astropy, NumPy e SciPy não foram reimplementados nesta documentação.

As provas de equivalência entre a versão original e os módulos estão em VALIDACAO.md e nos testes.

Referências bibliográficas

1. **Lomb, N. R. (1976).** Least-squares frequency analysis of unequally spaced data. *Astrophysics and Space Science*, **39**, 447–462. DOI: 10.1007/BF00648343.
2. **Scargle, J. D. (1982).** Studies in astronomical time series analysis. II. Statistical aspects of spectral analysis of unevenly spaced data. *The Astrophysical Journal*, **263**, 835–853. Artigo no ADS.
3. **Zechmeister, M.; Kürster, M. (2009).** The generalised Lomb–Scargle periodogram. A new formalism for the floating-mean and Keplerian periodograms. *Astronomy & Astrophysics*, **496**, 577–584. DOI: 10.1051/0004-6361:200811296.
4. **Baluev, R. V. (2008).** Assessing the statistical significance of periodogram peaks. *Monthly Notices of the Royal Astronomical Society*, **385**, 1279–1285. DOI: 10.1111/j.1365-2966.2008.12689.x.
5. **Schwarz, G. (1978).** Estimating the Dimension of a Model. *The Annals of Statistics*, **6**(2), 461–464. DOI: 10.1214/aos/1176344136.
6. **Efron, B. (1979).** Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics*, **7**(1), 1–26. DOI: 10.1214/aos/1176344552; cópia do artigo.
7. **Rousseeuw, P. J.; Croux, C. (1993).** Alternatives to the Median Absolute Deviation. *Journal of the American Statistical Association*, **88**(424), 1273–1283. DOI: 10.1080/01621459.1993.10476408.
8. **VanderPlas, J. T. (2018).** Understanding the Lomb–Scargle Periodogram. *The Astrophysical Journal Supplement Series*, **236**, 16. Artigo e registro bibliográfico.

As referências de software são a API do Astropy, a API de mínimos quadrados do NumPy e a API de otimização escalar do SciPy. As páginas `stable` podem acompanhar versões posteriores; a fórmula da FAP e a grade descritas acima também foram conferidas no código instalado do Astropy 7.0.1 usado pelo projeto na validação.